

Practica 2

Clasificación de frijoles mediante tecnicas de machine learning

1st Erick Franco Gaona

Departamento de Estudios Multidisciplinarios

Universidad de Guanajuato

Yuriria, México

e.francogaona@ugto.mx

Resumen—Las regresiones se utilizan a menudo para predecir situaciones de la vida real en la industria y la ciencia. Existen diversas técnicas para realizar regresiones como pueden ser regresiones lineales múltiples o bosques aleatorios. En este trabajo se presenta un caso de estudio de esas dos técnicas sobre un conjunto de datos público para revisar la diferencia de efectividad entre ambos métodos. Mientras que la regresión lineal múltiple obtuvo un 82 % de efectividad, los bosques aleatorios obtuvieron un 88 % a costa de un mayor tiempo de ejecución.

I. INTRODUCCIÓN

La clasificación consta en ordenar u organizar las cosas en un conjunto de categorías o clases. Puedes categorizar ideas, objetos o cualquier tipo de referencia. El concepto de clasificación tiene diferentes vertientes: aprendizaje supervisado, no supervisado, semi supervisado y por refuerzo. El aprendizaje supervisado cuenta con un conocimiento a priori, es decir para la tarea de clasificar un objeto dentro de una categoría o clase se tienen modelos ya clasificados (objetos agrupados que tienen características comunes). En la primera fase se tiene un conjunto de entrenamiento o de aprendizaje (para el diseño del clasificador) y otro llamado de prueba o de validación (para clasificación), estos sirven para construir un modelo o regla general para la clasificación. En la segunda fase se clasifican los objetos o muestras de las que se desconoce la clase a las que pertenecen. A diferencia del aprendizaje supervisado, el aprendizaje no supervisado o clustering no se cuenta con conocimiento a priori, por lo que se tiene un área de entrenamiento disponible para la tarea de clasificación. En este tipo de clasificación contamos con “objetos” o muestras que tienen un conjunto de características, de las que no sabemos a qué clase o categoría pertenece, entonces la finalidad es el descubrimiento de grupos de “objetos” cuyas características afines nos permitan separar las diferentes clases.

En ocasiones, es muy complicado disponer de un conjunto de datos completamente etiquetado. Este tipo de aprendizaje tiene un poco de los dos anteriores. Usando este enfoque, se comienza etiquetando manualmente algunos de los datos. Una vez se tenga una pequeña porción de datos

etiquetados, se entrena uno o varios algoritmos de aprendizaje supervisado sobre esa pequeña parte de datos etiquetados y se usan los modelos resultantes del entrenamiento para etiquetar el resto de los comentarios. Finalmente, se entrena un algoritmo de aprendizaje supervisado utilizando como etiquetas las etiquetadas manualmente y las generadas por los modelos anteriores. Por último, el aprendizaje por refuerzo es un método de aprendizaje automático que se basa en recompensar los comportamientos deseados y penalizar los no deseados. Es un aprendizaje que fija objetivos a largo plazo para obtener una recompensa general máxima y lograr una solución óptima. El juego es uno de los campos más utilizados para poner a prueba el aprendizaje por refuerzo. En estos casos, el agente recibe información sobre las reglas del juego y aprende a jugar por sí mismo. En un principio se comporta de manera aleatoria, pero con el tiempo empieza a aprender movimientos más sofisticados. Este tipo de aprendizaje se aplica también en otras áreas como la robótica, la optimización de recursos o sistemas de control.

En este trabajo se cuenta con un dataset público que posee 16 características de 6 diferentes tipos de frijol, por lo que, se utiliza el aprendizaje supervisado. En las siguientes secciones se explica la teoría y ejemplifica mediante el caso de estudio su aplicación.

II. TEORÍA

II-A. Clasificador bayesiano simple

El teorema de Bayes es utilizado para calcular la probabilidad de un suceso, teniendo información de antemano sobre ese suceso. Es posible calcular la probabilidad de un suceso A, sabiendo además que ese suceso cumple cierta característica que condiciona su probabilidad. El teorema de la probabilidad total hace inferencia sobre un suceso B, a partir de los resultados de los sucesos A. Por su parte, Bayes calcula la probabilidad de A condicionado a B. Para calcular la probabilidad tal como la definió Bayes en este tipo de sucesos, es necesaria la siguiente fórmula:

$$P[A_n/B] = \frac{P[B/A_n] * P[A_n]}{\sum P[B/A_i] * P[A_i]} \quad (1)$$

donde B es el suceso sobre el que se tiene información previa y A_n son los distintos sucesos condicionados. En la parte del numerador se encuentra la probabilidad condicionada, y el denominador la probabilidad total.

Los clasificadores NaiveBayes (NBC por sus siglas en inglés) son algoritmos de aprendizaje automático simples pero potentes. Se basan en la probabilidad condicional y el teorema de Bayes. SE deben seguir los siguientes pasos para implementar el algoritmo:

1. Convertir el conjunto de datos en una tabla de frecuencias
2. Crear una tabla de probabilidad calculando las correspondientes a que ocurran los diversos eventos o haciendo una distribución Gaussiana
3. La ecuación NaiveBayes se usa para calcular la probabilidad posterior de cada clase
4. La clase con la probabilidad posterior más alta es el resultado de la predicción

II-B. Clasificación vecino más cercano (K-NN)

El clasificador de vecinos más cercanos se basa en calcular las distancias entre el dato a clasificar y los ejemplos de entrenamiento para decidir a que clase pertenece dependiendo de la menor distancia. No define de forma explícita una frontera de separación entre clases. La frontera se define implícitamente a partir de la distancia a las muestras del conjunto de entrenamiento. No requiere una representación de cada imagen en forma de vector, únicamente la definición de una función de distancia entre dos imágenes. Se considera un método de lazy learning debido a que la generalización más allá de los datos de entrenamiento es demorada hasta que se hace una pregunta al sistema.

De igual forma, K vecinos más cercanos es uno de los algoritmos de clasificación más básicos y esenciales en Machine Learning. Pertenecce al dominio del aprendizaje supervisado y encuentra una aplicación intensa en el reconocimiento de patrones, la minería de datos y la detección de intrusos. Este algoritmo consiste en seleccionar un valor de K vecinos. Al momento del análisis los K datos más cercanos al valor que se desea predecir será la solución. Acá lo importante es seleccionar un valor de K acorde a los datos para tener una mayor precisión en la predicción. Si k es muy pequeño el modelo será muy sensitivo a puntos que son atípicos o con ruido. Si K es muy grande el modelo tiende a asignar siempre la clase más grande.

Algorithm 1 Clasificador vecinos cercanos NN

Require:

- D ▷ datos de entrenamiento
- k ▷ número de vecinos
- t ▷ dato para clasificar
- c ▷ clase para clasificar

Ensure: c

```

N ← 0
for d ∈ D do
  if |N| ≤ k then
    N = N ∪ d_i
  else
    if ∃ u ∈ N tal que sim(t, u) ≥ sim(t, d) then
      N = N - u
      N = N ∪ d_i
    end if
  end if
end for
c = clases para los mejores u ∈ N que son clasificados

```

Para el calculo de la distancia entre los vecinos se suelen utilizar la distancia euclidiana (ecuación 2) y distancia Manhattan (ecuación 3) siendo la primera la más común. La distancia euclidiana es un número positivo que indica la separación que tienen dos puntos en un espacio. La distancia entre dos puntos A y B de un espacio euclidiano es la longitud del vector AB perteneciente a la única recta que pasa por dichos puntos. Por otro lado, la distancia Manhattan dice que la distancia entre dos puntos es la suma de las diferencias absolutas de sus coordenadas. Es decir, es la suma de las longitudes de los dos catetos del triángulo rectángulo.

$$d_{ij} = \sqrt{\sum_{k=1}^n (x_{ki} - x_{kj})^2} \quad (2)$$

$$d(p, q) = \sum_i^n |p_i - q_i| \quad (3)$$

II-C. Árboles de decisión

La idea de la clasificación con árboles de decisión es simple: iterativamente se van generando particiones binarias (es decir de a dos agrupaciones) sobre la región de interés, buscando que cada nueva partición genere un subgrupo de datos lo más homogéneo posible. Primero se establece una condición. Dependiendo de si los datos cumplen o no la condición se tendrá una primera partición en dos subregiones. Y luego se repite el procedimiento anterior, una y otra vez, hasta que al final se obtengan agrupaciones lo más homogéneas posible, es decir con puntos que pertenezcan en lo posible a una sola categoría.

Para medir la homogeneidad se usa el índice Gini, que mide el grado de impureza de un nodo: índices Gini iguales a cero indican nodos puros (es decir con datos que pertenecen a una sola categoría), mientras que índices mayores que cero y con

valores hasta de uno indican nodos con impurezas (es decir con datos de más de una categoría).

$$Gini = 1 - (Probabilidad1)^2 - (Probabilidad2)^2 \quad (4)$$

Los pasos para realizar un árbol de decisión para clasificar son los siguientes:

1. Para crear la raíz del árbol, es decir la primera partición, se toman todas las características y, para cada una de ellas, se definen todos los posibles umbrales a que haya lugar. Cada umbral será simplemente el punto intermedio entre dos valores consecutivos de cada característica.
2. Para cada uno de estos umbrales se calcula la partición (nodo izquierdo y nodo derecho) y para cada nodo hijo se calcula el índice Gini. Con estos nodos hijos se calcula la función de costo del nodo padre, que es el promedio ponderado de los índices Gini de sus hijos.
3. Se toma el umbral (o nodo padre resultante) que tenga la función de costo con el menor valor posible, indicando que la partición obtenida es la más homogénea de todas las analizadas.
4. Una vez se haya realizado esta partición, se repite el mismo procedimiento de forma iterativa para los nodos resultantes, exceptuando los que sean nodos hoja

II-D. Bosques aleatorios

El bosque aleatorio tiende a combinar cientos de árboles de decisión y luego entrena cada árbol de decisión en una muestra diferente de las observaciones. Las predicciones finales del bosque aleatorio se realizan promediando las predicciones de cada árbol individual. El algoritmo de bosque aleatorio también puede ayudarte a encontrar características que son importantes en tu conjunto de datos. Esto se debe al algoritmo de Boruta, que selecciona características importantes en un conjunto de datos. El algoritmo funciona completando los siguientes pasos:

1. El algoritmo selecciona muestras en forma aleatoria de la base de datos proporcionada.
2. El algoritmo creará un árbol de decisión para cada muestra seleccionada. Luego obtendrá un resultado de predicción de cada árbol creado.
3. A continuación, se realizará la votación para cada resultado previsto. Para un problema de clasificación, usará la moda, y para un problema de regresión, usará la media.
4. El algoritmo seleccionará el resultado de predicción más votado como predicción final.

II-E. Máquina de vectores de soporte (SVM)

Las máquinas de vectores de soporte son una técnica que encuentra la mejor separación posible entre clases. Normalmente, los problemas de aprendizaje automático tienen muchísimas dimensiones. Así que, en vez de encontrar la línea óptima, el SVM encuentra el hiperplano que maximiza el margen de separación entre clases. Los vectores de soporte son los puntos que definen el margen máximo de separación del hiperplano que separa las clases. Se llaman vectores, en lugar de puntos, porque estos puntos tienen tantos elementos

como dimensiones tenga nuestro espacio de entrada. Es decir, estos puntos multidimensionales se representan con vector de n dimensiones.

Es bastante frecuente que los datos tengan ruido, que no estén etiquetados perfectamente, o que el problema sea tan difícil que, para unos pocos puntos, sea muy complicado clasificarlos correctamente. Para estos casos, podemos decirle al SVM, que preferimos que generalice bien para la mayoría de los casos, aunque algunos pocos casos del conjunto de entrenamiento no estén perfectamente clasificados. Lo que normalmente vamos buscando es la construcción de modelos de aprendizaje automático que generalicen bien.

En algunas ocasiones no hay forma de encontrar un hiperplano que permita separar dos clases. En estos casos decimos que las clases no son linealmente separables. Para resolver este problema podemos usar el truco del kernel. El truco del kernel consiste en inventar una dimensión nueva en la que podamos encontrar un hiperplano para separar las clases. Al añadir una dimensión nueva, es posible separar las clases con una superficie de decisión. También hay métodos para separar los datos (x_i, y_i) directamente aun no siendo separables linealmente, mediante funciones polinómicas y funciones de base radial (RBF).

II-F. Redes neuronales

Una red neuronal es un modelo simplificado que emula el modo en que el cerebro humano procesa la información: Funciona simultaneando un número elevado de unidades de procesamiento interconectadas que parecen versiones abstractas de neuronas. Las unidades de procesamiento se organizan en capas. Hay tres partes normalmente en una red neuronal : una capa de entrada, con unidades que representan los campos de entrada; una o varias capas ocultas; y una capa de salida, con una unidad o unidades que representa el campo o los campos de destino. Las unidades se conectan con fuerzas de conexión variables (o ponderaciones). Los datos de entrada se presentan en la primera capa, y los valores se propagan desde cada neurona hasta cada neurona de la capa siguiente. al final, se envía un resultado desde la capa de salida.

La red aprende examinando los registros individuales, generando una predicción para cada registro y realizando ajustes a las ponderaciones cuando realiza una predicción incorrecta. Este proceso se repite muchas veces y la red sigue mejorando sus predicciones hasta haber alcanzado uno o varios criterios de parada. Al principio, todas las ponderaciones son aleatorias y las respuestas que resultan de la red son, posiblemente, disparatadas. La red aprende a través del entrenamiento. Continuamente se presentan a la red ejemplos para los que se conoce el resultado, y las respuestas que proporciona se comparan con los resultados conocidos. La información procedente de esta comparación se pasa hacia atrás a través de la red, cambiando las ponderaciones gradualmente. A medida que progresa el entrenamiento, la red se va haciendo cada vez más precisa en

la replicación de resultados conocidos. Una vez entrenada, la red se puede aplicar a casos futuros en los que se desconoce el resultado.

III. RESULTADOS

Para realizar la práctica se programó en lenguaje Python (revisar Anexo A) los dos sistemas de regresión. Primero se obtuvo el conjunto de datos publico mpg-auto el cual contiene información de distintos autos que se relacionan con el rendimiento de gasolina como se muestra en la Tabla 1. Para ambos casos se tuvo que hacer un pre-procesamiento de los datos debido a que el archivo disponible no cuenta con información completa para todos los registros. Es importante mencionar que el conjunto de datos contiene registros sobre el modelo y al ser una variable categorica puede ser convertida a variable dummy. Las variables se normalizaron para quedar en el mismo rango. los datos se dividieron para entrenamiento y pruebas en una proporción 80/20 respectivamente.

Mediante la técnica de eliminación hacia atrás se optimizó la regresión lineal múltiple, colocando todas las variables x se fueron eliminando las variables que su valor P superaba el umbral del 5 % para el sistema. En este conjunto de datos en particular solo se eliminó una variable la aceleración que si bien superaba el 5 % de umbral, no lo superó por mucho pues obtuvo 6 % y se pudo dejar en el modelo.

MPG-auto dataset	
Dato	Tipo de dato
Millas por galón	continuo
Cilindros	discreto multivalor
Desplazamiento	continuo
Caballos de fuerza	continua
Peso	continuo
Aceleración	continua
Año del modelo	discreto multivaluado
Origen	discreto multivaluado
Nombre del coche	cadena

Tabla I
CONJUNTO DE DATOS MPG-AUTO

Para los bosques aleatorios el proceso es similar, se ejecuta con el pre-procesamiento antes mencionado. Los resultados obtenidos se midieron mediante las métricas R^2 y R^2 ajustada como se observa en la Tabla 2.

Regresión lineal múltiple	Bosques aleatorios
$R^2 = 82.54 \%$	$R^2 = 82.27 \%$
$R^2 = 82.54 \%$	$R^2 = 88.22 \%$

Tabla II
RESULTADOS DEL ENTRENAMIENTO

CONCLUSIONES

Como se pudo observar en los resultados, los bosques aleatorios son más robustos que la regresión lineal múltiple aunque requiere más tiempo de procesamiento. Sin embargo, actualmente el poder de cómputo es cada vez mayor por lo que el tiempo se reduce con el paso de los años mediante el hardware. Durante el entrenamiento no se tomó en cuenta la variable categorica del modelo del auto ya que al intentar

convertirla en variable dummy, eran demasiadas variables que no podían ser procesadas. Para trabajo futuro se puede modificar manualmente el conjunto de datos para asegurarse en reducir esa variable y colocar solo la marca del vehículo. No se realizó en este trabajo ya que el rendimiento obtenido es considerablemente óptimo por lo que podría no valer la pena incluir esas variables dummies.

Las regresiones no son 100 % efectivas ya que no siempre se va a ajustar perfectamente a los valores a predecir pero si se puede hacer una aproximación cercana mediante la optimización de parámetros de los métodos. Además, es bueno revisar de ser posible los datos que se proporcionan para el entrenamiento y eliminar los valores atípicos para evitar errores. El sobreajuste es un problema que trata de evitar los bosques aleatorios y que generalmente cumple su función, pero dependiendo de la aplicación puede optarse por una técnica u otra. A pesar de no ser confiables en su totalidad, las predicciones que es capaz de realizar alguno de estos métodos son lo suficientemente robustos para utilizarse en la industria ajustando el modelo lo mejor posible para mejores resultados.

REFERENCIAS

- [1] Yang, Q. (2017). Regression. In: Schintler, L., McNeely, C. (eds) Encyclopedia of Big Data. Springer, Cham. <https://doi.org/10.1007/978-3-319-32001-4-174-1>.
- [2] Probabilidad y estadística aplicadas a la ingeniería, Douglas C. Montgomery y George C. Runger. Limusa Wiley, 2002. Segunda edición.
- [3] Rokach, L., Maimon, O. (2005). Decision Trees. In: Maimon, O., Rokach, L. (eds) Data Mining and Knowledge Discovery Handbook. Springer, Boston, MA. <https://doi.org/10.1007/0-387-25465-X-9>.
- [4] Cutler, A., Cutler, D.R., Stevens, J.R. (2012). Random Forests. In: Zhang, C., Ma, Y. (eds) Ensemble Machine Learning. Springer, Boston, MA. <https://doi.org/10.1007/978-1-4419-9326-7-5>.

IV. ANEXO A

Lectura de conjunto de datos y separarlos en variables dependientes e independientes y eliminación de valores incompletos.

```
1 cols=["MPG", "cylinders", "displacement", "
   horsepower", "weight", "acceleration", "
   model_year", "origin"]
2 dataset=pd.read_csv("auto-mpg.data", na_values="
   ?", comment='\t', sep=' ', skipinitialspace=
   True, names=cols)
3 X=dataset.iloc[:,1:].values
4 Y=dataset.iloc[:,0].values
```

Normalizado de datos.

```
1 sc=StandardScaler()
2 X=sc.fit_transform(X)
```

Separando el conjunto de datos.

```
1 X_train, X_test, Y_train, Y_test=
   train_test_split(X,Y, test_size=0.2,
   random_state=0)
```

IV-A. Regresión lineal múltiple

Ejecución de la regresión lineal múltiple y cálculo de las métricas de evaluación.

```

1  regresion=LinearRegression()
2  regresion.fit(X_train, Y_train)
3  ypred=regresion.predict(X_test)
4
5  print("R^2: ", r2_score(Y_test, ypred))
6  print("R^2 ajustada: ", 1 - (1-r2_score(Y_test,
      ypred))*(len(Y)-1)/(len(Y)-X.shape[1]-1))

```

IV-B. Bosques aleatorios

Ejecución del bosque aleatorio estableciendo 10 árboles y calculo de las metricas de evaluación.

```

1  regresion=RandomForestRegressor(n_estimators=10
      ,random_state=0)
2  regresion.fit(X_train, Y_train)
3  ypred=regresion.predict(X_test)
4
5  print("R^2: ", r2_score(Y_test, ypred))
6  print("R^2 ajustada: ", 1 - (1-r2_score(Y_test,
      ypred))*(len(Y)-1)/(len(Y)-X.shape[1]-1))

```